

Dokumentácia k Zadaniu 4

Matej Maďar, Marek Malina

Cieľom zadania bolo oboznámiť sa s metódou 3D Gaussian Splatting. Prešli sme celým postupom od fotografií po interaktívny 3D viewer, najprv na datasete tanku M60 a potom na vlastnoručne nasnímanej scéne s ruksakom. Postup sme realizovali podľa NAVOD.md v Docker kontajneri s NVIDIA CUDA 11.8.

1. Referenčný dataset M60

1.1 Popis datasetu


Ako referenčný dataset sme použili scénu M60 z kolekcie Tanks and Temples (tanksandtemples.org). Dataset obsahuje fotografie vojenských tankov v interiéri hangáru. Z datasetu sme použili iba priečinok s fotografiami (input/), predpočítané dáta sme nepoužili.



Obr. 1 - Obrázok z datasetu M60, img 00141.jpg

1.2 Spustenie prostredia

Docker kontajner sme spustili príkazom `./run.sh`. Pri prvom spustení prebehol build obrazu, ktorý trval približne 50 minút. Robilo sa stiahnutie základného CUDA obrazu a inštalácia všetkých závislostí. Na terminál bolo vypísané varovanie o chýbajúcom NVIDIA container runtime, no kontajner sa spustil a tréning prebehol korektne.



Obr. 2 - build Docker kontajnera, sťahovanie CUDA

1.3 Príprava dát v COLMAP

Fotografie tankov M60 sme vložili do priečinka data/moja_scena/input/. Spustili sme colmap gui a postupne vykonali všetky kroky:

- Feature Extraction: kamerový model SIMPLE_PINHOLE.
- Feature Matching: režim Sequential.
- Reconstruction: COLMAP vypočítal pozície kamier a vytvoril riedky 3D mrak bodov.
- Export modelu: File -> Export model do distorted/sparse/0/ (


Následne sme spustili convert.py, ktorý opravil distortion a pripravil priečinok images a sparse/0/ pre tréovanie:

```
python3 convert.py -s data/moja_scena --skip_matching
```

1.4 Trénovanie a vizualizácia

Vstupné snímky boli automaticky rescalované na 1.6K. Celý tréning trval cca 60 minút.


```
python3 train.py -s data/moja_scena --data_device cpu
```




Obr. 3 - Priebeh tréovania datasetu m60

Po dokončení sme spustili interaktívny viewer. Scéna s tankami sa zobrazila plynulo okolo 70 FPS.

```
SIBR_gaussianViewer_app -m output/6f97a2b6-c
```

Obr. 4 - SIBR viewer, pohľad na tanky M60




Obr. 5 - SIBR viewer, druhý pohľad na tank M60

1.5 Porovnanie datasetu a modelu



Obr. 6 - img 00014.jpg z datasetu



Obr. 7 - SIBR viewer, tretí pohľad na tanky M60, znížený scaling

2. Vlastná scéna - Ruksak

2.1 Snímanie scény a nastavenia kamery

Ako vlastnú scénu sme zvolili ruksak. Snímanie sme robili kamerou Ximea MX031MG-SY pomocou skriptu dataset.py. Použili sme pevne nastavené parametre kamery:

- rozlíšenie: 2464 x 2056 px
- expozícia: 15 000 μ s
- gain: 0.0 dB (zodpovedá najnižšiemu ISO)
- vyváženie bielej: R = 1.6, G = 1.0, B = 1.8
- ohnisková vzdialenosť: fixná, objektív kamery bez zmeny počas celého snímania
- formát: PNG
- Počet snímok: 177

Pohybovali sme sa okolo objektu v kruhu na viacerých výškach, každý bod scény bol viditeľný z aspoň troch uhlov.




Obr. 8 Ruksak fotený so Ximea kamerou

2.2 Predspracovanie a COLMAP

Pred spustením COLMAP sme fotografie downscalovali tak, aby dlhšia strana nepresahovala 1600px, lebo kamera Ximea má príliš vysoké rozlíšenie na priame spracovanie v COLMAP. Postup v COLMAP bol:

- Feature Extraction: kamerový model SIMPLE_PINHOLE
- Feature Matching: režim Exhaustive
- Reconstruction: COLMAP spracoval 175 z 177 fotografií, vytvoril 20 929 bodov
- Export a convert.py: rovnaký postup ako pri M60.




Obr. 9 - COLMAP GUI, sparse reconstruction ruksaka: 175 snímok, 20 929 bodov


2.3 Trénovanie

Pri vlastnom datasete sme použili parametre `--eval`, `--resolution 2` (zníženie rozlíšenia na polovicu) a `--iterations 7000` pre rýchlejšie tréningovanie:

```
python3 train.py -s data/moja_scena --data_device cpu --eval --iterations 7000 --resolution 2
```

Obr. 12 - SIBR viewer, rekonštrukcia ruksaka




Obr. 13 - SIBR viewer, rekonštrukcia ruksaka

2.5 Porovnanie datasetu a modelu



Obr. 14 - náš dataset, img_0166



Obr. 15 - SIBR viewer, rekonštrukcia ruksaka

3 Vyhodnotenie

3.1 Vizuálne porovnanie

Vidíme, že obe scény dosiahli porovnateľnú kvalitu. Tvar aj textúra hlavného objektu sú v oboch prípadoch zachované dobre, pričom najväčší rozdiel je v pozadí, kde sa pri ruksaku objavujú výraznejšie artefakty a rozmazanie. Ruksak bol mierne viac rozmazaný, ale záleží dosť na tom, kde sa v modeli nachádzame. Rozdiel medzi scénami je teda skôr v kvalite okolia než v samotnom objekte záujmu.

3.2 Porovnanie metrík

Tabuľka porovnania oboch datasetov.

Dataset	PSNR	SSIM	Poznámka
M60	22.38 dB	0.7632	Štandardné parametre, 30k iterácii
Ruksak	23.64 dB	0.889	--resolution 2 – iterations 7000 –eval

Pri ruksaku sme mali LPIPS: 0.338.

PSNR: pod 22 dB = slabá, 22 až 26 dB = prijateľná, 26 až 29 dB = dobrá, nad 29 dB = výborná